

Practica: Filtro Anti-Spam con Naive Bayes

El Naive Bayes es muy popular entre los filtros anti-spam del correo-e. Principalmente por su sencillez en la implementación y los buenos resultados que se obtienen. El objetivo de esta práctica es un ejercicio de implementación de procedimiento más sencillo anti-spam bayesiano. En el artículo [1] aparecen diferentes modificaciones al Naive Bayes además de la explicación del procedimiento (lectura recomendada!!).

1 Naive Bayes

El teorema de Bayes nos permite obtener, dado un correo-e entrante, la probabilidad de clasificarlo con *Spam* o *Ham* (C_{Spam}), dado por la igualdad:

$$P(C_{Spam} / \text{mensaje}_0) = \frac{P(C_{Spam} \cap \text{mensaje}_0)}{P(\text{mensaje}_0)} = \frac{P(\text{mensaje}_0 / C_{Spam}) P(C_{Spam})}{P(\text{mensaje}_0 / C_{Spam}) P(C_{Spam}) + P(\text{mensaje}_0 / \overline{C_{Spam}}) P(\overline{C_{Spam}})} \quad (1)$$

donde C_{Spam} es la categoría Spam, (frente a la categoría complementaria $\overline{C_{Spam}}$) y mensaje_0 es el mensaje que queremos clasificar. Intuitivamente si

$$P(C_{Spam} / \mathbf{x}) > \text{Umbral} \quad (2)$$

para un valor alto de $\text{Umbral} \in [0, 1]$ entonces clasificaríamos el mensaje entrante como *Spam*. Para clasificadores binarios, un valor razonable de Umbral es el que da la opción mayoritaria ($\text{Umbral} = 0.5$).

1.1 Obtención de las probabilidades

Por lo tanto, dado lo anterior, se deben especificar:

- Probabilidades incondicionales, expresadas como frecuencias relativas (del conjunto de datos) de aparición del suceso de interés, i.e.:

$$P(C_{Spam}) \approx \frac{\# \{\text{mensaje spam}\}}{\# \{\text{total de mensajes}\}} \quad (3)$$

$$P(\overline{C_{Spam}}) = 1 - P(C_{Spam}) \quad (4)$$

- Probabilidades condicionales. Procederemos con la versión *naive* en donde se debe transformar cada *mensaje* en un vector de longitud fija (digamos m-dimensional) indicando para cada coordenada el resultado de Bernoulli (0/1) si el atributo i-ésimo está presente o no en el mensaje. Entonces para el mensaje_i , transformado en el vector de características m-dimensional dado por $(t_{i,1}, t_{i,2}, \dots, t_{i,m})$ con valores $t_{i,j} \in \{0, 1\}$, $j = 1, 2, \dots, m$, podemos expresar la probabilidad condicionada como:

$$P(\text{mensaje}_0 / C_{Spam}) = P(\mathbf{x}_0 / C_{Spam}) = \prod_{j=1}^m P(x_j / C_{Spam})^{t_{0,j}} (1 - P(x_j / C_{Spam}))^{1-t_{0,j}}$$

con $P(X_j = x_j / C_{Spam})$ la probabilidad de que la j-ésima variable de Bernoulli tome el atributo j-ésimo condicionado a que el mensaje pertenece a la clase C_{Spam} . Dicha probabilidad se puede estimar a partir de los datos como:

$$P(X_j = x_j / C_{Spam}) \approx \frac{\# \{\text{mensajes spam con la característica } X_j\}}{\# \{\text{total de mensajes spam}\}}$$

Análogamente se obtendrían las probabilidades condicionadas por la categoría $\overline{C_{Spam}}$:

$$P(\text{mensaje}_0 / \overline{C_{Spam}}) = P(\mathbf{x}_0 / \overline{C_{Spam}}) = \prod_{j=1}^m P(x_j / \overline{C_{Spam}})^{t_{0,j}} (1 - P(x_j / \overline{C_{Spam}}))^{1-t_{0,j}}$$

y

$$P(X_j = x_j / \overline{C_{Spam}}) \approx \frac{\# \{\text{mensajes no-spam con la característica } X_j\}}{\# \{\text{total de mensajes no-spam}\}}$$

2 Datos

Genéricamente, se dispondrá de una colección de correos-e, digamos de tamaño M , clasificados entre correo-e Spam y No-Spam. Cada uno de los mensajes se debe transformar en un vector m -dimensional el cual debe recoger las características necesarias para que pueda el sistema clasificar correos nuevos como Spam/No-Spam.

2.1 Spambase

En el *UC Irvine Machine Learning Repository* está el conjunto de datos [Spambase](#) el cual contiene 4601 correo-e transformados y clasificados en Spam/No-Spam. Ver la descripción de los 57 atributos/columnas asociados a cada mensaje en el archivo *spambase.names*.

Este conjunto se debe dividir aleatoriamente en dos, uno de entrenamiento (90% de las filas) y el otro de test (10% restante). El conjunto de entrenamiento para usará para calcular las probabilidades necesarias para obtener la $P(C_{Spam}/\text{mensaje}_j)$ evaluadas en cada $j \in \text{test}$

3 Resultados y análisis

- Generar una función que dé la probabilidad de que dado un mensaje se clasifique como Spam (1), dada la matriz de datos de entrenamiento y el vector de clasificación.
- Obtener las probabilidades de clasificación para los mensajes dados en el conjunto *test*.
- Para un valor de $Umbral=0.5$, computar la tabla 2x2 de clasificación correcta/incorrecta (matriz de confusión en terminología IA):

VALORES PREDICCIÓN	Verdaderos positivos	Falsos Positivos
	Falsos Negativos	Verdaderos Negativos
VALORES REALES		

- Verdadero positivo: El mensaje es positivo y la prueba predijo también que era positivo.
- Verdadero negativo: El valor real es negativo y la prueba predijo también que el resultado era negativo.
- Falso negativo: El valor real es positivo, y la prueba predijo que el resultado es negativo. Esto es lo que en estadística se conoce como error tipo II
- Falso positivo: El valor real es negativo, y la prueba predijo que el resultado es positivo. Esto es lo que en estadística se conoce como error tipo I

Identificando Positivo/Negativo como Spam/No-Spam y valores reales la clasificación real del mensaje y valores predicción como los valores que el naive bayes da como clasificación.

- Obtener la matriz de confusión para los valores de Umbral 0.01, 0.02, ..., 0.98, 0.99. Realizar un gráfico donde el eje de abscisas sea el umbral, y como eje de ordenadas:
 - Proporción de verdaderos positivos
 - Proporción de verdaderos negativos
 - Proporción de mensajes clasificados correctamente.

A la vista del gráfico anterior, ¿qué conclusiones se pueden obtener para el valor de umbral?

References

- [1] Metsis, V. Androutsopoulos, I., Paliouras G. (2006). Spam filtering with Naive Bayes - Which Naives Bayes?.
https://www2.aueb.gr/users/ion/docs/ceas2006_paper.pdf